Jin-Soo Kim (jinsoo.kim@snu.ac.kr)

Systems Software & Architecture Lab.

Seoul National University

Jan. 3 – 14, 2022

Python for Data Analytics

Pandas II



Outline

- Why Pandas?
- Pandas Series
- Pandas DataFrame
 - Creating DataFrame
 - Manipulating Columns
 - Manipulating Rows
 - Arithmetic operations
 - Group Aggregation
 - Hierarchical Indexing
 - Combining and Merging
 - Time Series Data

Arithmetic Operations

Arithmetic (I)

```
df1 = pd.DataFrame(np.random.randint(0,10,size=(4,2)),
                      index=list('abcd'))
df2 = pd.DataFrame(np.random.randint(0,10,size=(4,2)),
                      index=list('abde'))
df1 + df2
                df1 - df2
                                 df1 * df2
                                                 df1 / df2
                                       0
 a 17.0
         9.0
                 a -1.0
                         -7.0
                                  a 72.0
                                          8.0
                                                  a 0.888889
                                                             0.125
   18.0
         3.0
                     0.0
                         3.0
                                  b 81.0
                                          0.0
                                                     1.000000
                                                               inf
 c NaN NaN
                 c NaN NaN
                                  c NaN NaN
                                                        NaN
                                                              NaN
   11.0
         4.0
                     7.0
                         4.0
                                  d 18.0
                                          0.0
                                                     4.500000
                                                               inf
   NaN NaN
                    NaN NaN
                                  e NaN NaN
                                                        NaN
                                                              NaN
```

		0	1			(0	1	
í	a	8	1		а	Ç	9	8	
ŀ	b	9	3		b	Ç	9	0	
(С	1	7		d	2	2	0	
(9 f1	4		е		4 F2	7	
(df1	L /	10			df:	2 -	- e	.5
_		0)	1				0	1
	а	0.8	3 0	1.1		а	9	.5	8.5
	b	0.9	0	.3		b	9	.5	0.5
	С	0.1	0	.7		d	2	.5	0.5
	d	0.9	0	.4		е	4	.5	7.5

Arithmetic (2)

- Alignment is performed on both rows and columns
- The result will be all NANs if no column or row labels are in common

	b	С	d			b	d	е		b	С	d	е
x	0.0	1.0	2.0		w	0.0	1.0	2.0	u	NaN	NaN	NaN	NaN
у	3.0	4.0	5.0	+	x	3.0	4.0	5.0	= w	NaN	NaN	NaN	NaN
z	6.0	7.0	8.0		у	6.0	7.0	8.0	x	3.0	NaN	6.0	NaN
					u	9.0	10.0	11.0	у	9.0	NaN	12.0	NaN
									z	NaN	NaN	NaN	NaN

```
      m
      0.0
      1.0
      p
      2.0
      3.0
      p
      2.0
      3.0
      m
      NaN
      NaN
      NaN
      NaN
      NaN

      n
      NaN
      NaN
      NaN
      NaN
      NaN
      NaN

      n
      NaN
      NaN
      NaN
      NaN
      NaN

      n
      NaN
      NaN
      NaN
      NaN
      NaN

      n
      NaN
      NaN
      NaN
      NaN
      NaN
```

Arithmetic Methods

Operation	Meaning
df1.add(df2)	df1 + df2
df1.sub(df2)	df1 - df2
df1.div(df2)	df1 / df2
df1.floordiv(df2)	df1 // df2
df1.mul(df2)	df1 * df2
df1.pow(df2)	df1 ** df2
df1.radd(df2)	df2 + df1
df1.rsub(df2)	df2 - df1
df1.rdiv(df2)	df2 / df1
df1.rfloordiv(df2)	df2 // df1
df1.rmul(df2)	df2 * df1
df1.rpow(df2)	df2 ** df1

• fill_value can be specified

- Existing missing values and any new elements is set to this value
- If data in both corresponding DataFrame locations is missing, the result will be NaN

							df1	.ad	d(d	f2,	fill	_valu	e=0)
	b	С	d		b	d	е			b	С	d	е
x	0.0	1.0	2.0	w	0.0	1.0	2.0		u	9.0	NaN	10.0	11.0
у	3.0	4.0	5.0 +	X	3.0	4.0	5.0	=	w	0.0	NaN	1.0	2.0
z	6.0	7.0	8.0	у	6.0	7.0	8.0		x	3.0	1.0	6.0	5.0
				u	9.0	10.0	11.0		у	9.0	4.0	12.0	8.0
									Z	6.0	7.0	8.0	NaN

Applying NumPy Universal Function

- A universal function (ufunc) operates on ndarrays in an element-byelement fashion
 - np.fabs(), np.exp(), np.sqrt(), np.log(), ...

	а	b	С	np.	sqrt(df)			df.a	apply(np.ex	o)	
R0	0.0	1.0	2.0		a	b	С		а	b	С
R1	3.0	4.0	5.0	R0	0.000000	1.000000	1.414214	R0	1.000000	2.718282	7.389056
R2	6.0	7.0	8.0	R1	1.732051	2.000000	2.236068	R1	20.085537	54.598150	148.413159
R3	9.0	10.0	11.0	R2	2.449490	2.645751	2.828427	R2	403.428793	1096.633158	2980.957987
				R3	3.000000	3.162278	3.316625	R3	8103.083928	22026.465795	59874.141715

Applying Functions

- df.apply(func, axis=0, ...) or series.apply(func, ...)
 - Apply a function along an axis of the DataFrame or on values of Series
 - axis=0 or axis='index': apply func to each column (default)
 - axis=1 or axis='columns': apply func to each row
- df.applymap(func, na_action=None, ...)
 - Apply a function to a Dataframe elementwise
 - no_action: if 'ignore', propagate NaN values, without passing them to func

	DataFrame	Series
apply()	\checkmark	\checkmark
applymap()	√	X
map()	X	\checkmark

- series.map (func, na_action=None, ...)
 - Map values of Series according to input correspondence

Applying Functions: Example

```
df['S'] = df.apply(np.sum, axis=1) | df.loc['e'] = df.apply(np.average, axis=0)
                                                                      df['T'] = df.apply(lambda x: x.max() - x.min(), axis=1)
                                 df
                                                                      df
  df
df
    XYZ
                                     X Y Z
                    XYZS
                                                                                      S
  a 3 1 6
                  a 3 1 6 10
                                 a 3.00 1.0 6.0 10.00
                                                                       a 3.00 1.0 6.0 10.00 9.00
                  b 0 1 8 9
                                 b 0.00 1.0 8.0 9.00
      1 8
                                                                       b 0.00 1.0 8.0
                                                                                    9.00 9.00
                  c 3 6 2 11
                                 c 3.00 6.0 2.0 11.00
  c 3 6 2
                                                                       c 3.00 6.0 2.0 11.00 9.00
                  d 3 0 2 5
                                 d 3.00 0.0 2.0 5.00
  d 3 0 2
                                                                       d 3.00 0.0 2.0
                                                                                    5.00 5.00
                                 e 2.25 2.0 4.5 8.75
                                                                       e 2.25 2.0 4.5 8.75 6.75
```

	X	Υ	Z	M	N
а	3	1	6	36	Yes
b	0	1	8	64	No
С	3	6	2	4	No
d	3	0	2	4	Yes



	X	Υ	Z	M	N
а	3	1	6	36	1
b	0	1	8	64	0
С	3	6	2	4	0
d	3	0	2	4	1

	X	Υ	Z	s	Т
а	1.732051	1.000000	2.449490	3.162278	3.000000
b	0.000000	1.000000	2.828427	3.000000	3.000000
С	1.732051	2.449490	1.414214	3.316625	3.000000
d	1.732051	0.000000	1.414214	2.236068	2.236068
е	1.500000	1.414214	2.121320	2.958040	2.598076

Encoding Text to Numbers

- series.factorize(...) or pd.factorize(values,...)
 - Encode the object as an enumerated type or categorical variable
 - Useful for obtaining a numerical representation of an array for distinct values
 - Return two arrays: an integer array and the corresponding unique values

```
Name Type
Tom INFJ
Bob ISTJ
Andy INFJ
Mary ENTP
Ann ESFP
```

```
df['Type'] = codes
df
```

	Name	Туре
0	Tom	0
1	Bob	1
2	Andy	0
3	Mary	2
4	Ann	3

One Hot Encoding

- pd.get_dummies(df, prefix=None, prefix_sep='_', columns=None, ...)
 - Convert categorical variable into dummy/indicator variables

pd.get dummies(df)

- prefix: string to append DataFrame column names
- prefix_sep: If appending prefix, delimiter to use
- columns: Column names in the DataFrame to be encoded. If None, all the columns with object or category dtype will be converted

	value	color
0	143	red
1	23	blue
2	46	red
3	0	green
4	78	blue

	value	color_blue	color_green	color_red
0	143	0	0	1
1	23	1	0	0
2	46	0	0	1
3	0	0	1	0
4	78	1	0	0

OneHotEncoder in Scikit-learn is more recommended (sklearn.preprocessing.OneHotEncoder)

Common Statistical Functions

Method	Description
count()	Number of non-null observations
sum()	Sum of values
mean()	Mean of values
median()	Arithmetic median of values
min()	Minimum
max()	Maximum
std()	Bessel-corrected sample standard deviation
var()	Unbiased variance
skew()	Sample skewness (3rd moment)
kurt()	Sample kurtosis (4th moment)
quantile()	Sample quantile (value at %)
mad()	Mean absolute deviation from mean value
cov()	Unbiased covariance
corr()	Correlation

	Male	Female	Household		
District					
Gwanak	257638	256917	275248		
Gangnam	260358	283727	234021		
Songpa	326602	350071	281417		
Jung	66193	69128	63594		
df.House	nold.mea	an()			
213570.0					
df.Male.n	nax()				
326602					
df.loc['S	Songpa']].sum()			
958090					
<pre>df['Female'].std()</pre>					
120431.30086035219					

idxmax() and idxmin()

- df.idxmax([axis=0], [skipna=True], ...)
 - Return index of first occurrence of maximum over requested axis
- df.idxmin([axis=0], [skipna=True], ...)
 - Return index of first occurrence of minimum over requested *axis*

```
      a
      b
      c

      W
      3
      9
      8

      X
      9
      0
      6

      Y
      4
      5
      7

      Z
      8
      7
      2
```

```
df.idxmax()
     Χ
dtype: object
df.idxmin(axis=1)
     b
dtype: object
df['a'].idxmax()
'X'
df.loc['X'].idxmin()
'h'
```

Sorting DataFrame by Index

- df.sort_index(axis=0, level=None, ascending=True, ...)
 - Sort by labels along an axis
 - axis=0 or axis= 'index': sort along the rows (default)
 - axis=| or axis=|columns|: sort along the columns
 - level: sort on values in specified index level

District	Name			
Gwanak	관악구	257638	256917	275248
Gangnam	강남구	260358	283727	234021
Songpa	송파구	326602	350071	281417
Jung	중구	66193	69128	63594

Male Female Household

df.sort	index(axis=0.	<pre>ascending=False)</pre>

Male	Female	Household

District	Name			
Songpa	송파구	326602	350071	281417
Jung	중구	66193	69128	63594
Gwanak	관악구	257638	256917	275248
Gangnan	강남구	260358	283727	234021

		Male	Female	Household
District	Name			
Gangnam	강남구	260358	283727	234021
Gwanak	관악구	257638	256917	275248
Songpa	송파구	326602	350071	281417
Jung	중구	66193	69128	63594

Sorting DataFrame by Values

- df.sort_values(by, axis=0, ascending=True, ...)
 - Sort by the values along either axis
 - by: name or list of names to sort by
 - axis: axis to be sorted

df.sort_values('Male')

df.sort_values('Songpa', axis=1)

	Male	Female	Household
District			
Gwanak	257638	256917	275248
Gangnam	260358	283727	234021
Songpa	326602	350071	281417
Jung	66193	69128	63594

	Male	Female	Household
District			
Jung	66193	69128	63594
Gwanak	257638	256917	275248
Gangnam	260358	283727	234021
Songpa	826602	350071	281417

	Household	Male	Female
District			
Gwanak	275248	257638	256917
Gangnam	234021	260358	283727
Songpa	281417	326602	350071
Jung	63594	66193	69128

Ranking DataFrame

- df.rank (axis=0, method='average', ascending=True, ...)
 - Compute numerical data ranks (I through n) along axis
 - axis: index to direct ranking
 - method: how to rank the records that have the same value (tie-breaking rule)
 -- 'average', 'min', 'max', 'first' or 'dense'

df['average'] =
<pre>df.score.rank(method='average',</pre>
ascending=False

	name	score	average	min	max	first	dense
0	kim	100	1.0	1.0	1.0	1.0	1.0
1	lee	80	6.0	5.0	7.0	5.0	4.0
2	park	95	2.5	2.0	3.0	2.0	2.0
3	choi	80	6.0	5.0	7.0	6.0	4.0
4	seo	80	6.0	5.0	7.0	7.0	4.0
5	hong	90	4.0	4.0	4.0	4.0	3.0
6	min	95	2.5	2.0	3.0	3.0	2.0

Group Aggregation

Example DataFrame Object

	Α	В	С	D
0	foo	one	-1.307901	1.174486
1	bar	one	-0.409657	0.872421
2	foo	two	-1.278086	0.028901
3	bar	three	0.315299	-2.273053
4	foo	two	-0.147411	-0.892378
5	bar	two	0.218316	-0.693276
6	foo	one	-1.024522	-0.358686
7	foo	three	1.996648	-0.273449

```
df[df.A == 'foo']
                                   df[df.A == 'bar']
                                        Α
                                              В
                                                       С
                    С
     Α
                                                                 D
                                    1 bar
                                            one -0.409657
                                                           0.872421
 0 foo
         one -1.307901
                       1.174486
                                                 0.315299
                                                          -2.273053
                                    3 bar
                                           three
         two -1.278086
                        0.028901
 2 foo
                                    5 bar
                                            two 0.218316 -0.693276
         two -0.147411 -0.892378
 4 foo
   foo
         one -1.024522
                       -0.358686
 7 foo three 1.996648 -0.273449
```

Groupby and Aggregation

- df.groupby(by, axis=0, ...)
 - Used to group large amounts of data and compute operations on these groups
 - by: label, function, a list of labels, ...
 (Used to determine the groups)
 - axis: 0 or 'index' for rows, I or 'columns' for columns (default: 0)
- Aggregation stat functions after grouping
 - mean(), sum(), median(), var(), etc.

```
g = df.groupby('A')
g.mean()
                          D
  Α
       0.041319
                  -0.697969
 foo -0.352255
                  -0.064225
g.corr()
               С
                        D
  Α
         1.000000
                  -0.920023
 bar
        -0.920023
                  1.000000
         1.000000
                 -0.404475
     D -0.404475
                  1.000000
```

Iterating over Groups

```
g.get_group('bar')

A B C D

1 bar one -0.409657 0.872421
3 bar three 0.315299 -2.273053
5 bar two 0.218316 -0.693276

g.get_group('foo')
```

```
Α
                     С
                               D
        one -1.307901
                        1.174486
0 foo
         two -1.278086
                        0.028901
  foo
        two -0.147411
                       -0.892378
  foo
        one -1.024522
                        -0.358686
  foo
       three
              1.996648 -0.273449
7 foo
```

```
for key, items in g:
    print(f'{key}:')
    print(g.get group(key))
bar:
            В
                                  D
   bar
          one -0.409657
                          0.872421
   bar
        three
                0.315299 -2.273053
   bar
                0.218316 -0.693276
          two
foo:
     Α
            В
                                  D
   foo
          one -1.307901
                          1.174486
   foo
          two -1.278086
                          0.028901
   foo
          two -0.147411 -0.892378
   foo
6
          one -1.024522 -0.358686
   foo
        three
                1.996648 -0.273449
```

Accessing a Group

Get a group's contents

```
g.get_group('bar')
```

```
        A
        B
        C
        D

        1
        bar
        one
        -0.409657
        0.872421

        3
        bar
        three
        0.315299
        -2.273053

        5
        bar
        two
        0.218316
        -0.693276
```

```
g.get_group('bar')['C'].values
array([-0.409657, 0.315299, 0.218316])
```

```
df.groupby('A')['C'].mean()
Α
       0.041319
bar
foo
      -0.352254
Name: C, dtype: float64
df.groupby('A')[['C']].mean()
 Α
   0.041319
bar
   -0.352254
df.groupby('A')[['C','D']].mean()
          C
                  D
 Α
    0.041319 -0.697969
   -0.352254 -0.064225
```

Describing a Group

g.describe()

	С							
	count	mean	std	min	25%	50%	75%	max
Α								
bar	3.0	0.041319	0.393556	-0.409657	-0.095670	0.218316	0.266807	0.315299
foo	5.0	-0.352255	1.394782	-1.307901	-1.278086	-1.024522	-0.147411	1.996648
	D							
	count	mean	std	min	25%	50%	75%	max
	3.0	-0.697969	1.572742	-2.273053	-1.483164	-0.693276	0.089573	0.872421
	5.0	-0.064225	0.768016	-0.892378	-0.358686	-0.273449	0.028901	1.174486

Grouping by Multiple Columns

```
gm = df.groupby(['A','B'])
gm.mean()
```

D

Α	В		
bar	one	-0.409657	0.872421
	three	0.315299	-2.273053
	two	0.218316	-0.693276
foo	one	-1.166211	0.407900
	three	1.996648	-0.273449
	two	-0.712749	-0.431739

gm.mean().unstack()

	С			D		
В	one	three	two	one	three	two
Α						
bar	-0.409657	0.315299	0.218316	0.872421	-2.273053	-0.693276
foo	-1.166211	1.996648	-0.712749	0.407900	-0.273449	-0.431739

Grouping by List/Dict

years = [2019,2020,2020,2018,2018,2020,2020,2018]
df[['C','D']].groupby(years).mean()

	С	D
2018	0.721512	-1.146293
2019	-1.307901	1.174486
2020	-0.623487	-0.037660

	Α	В	С	D
0	foo	one	-1.307901	1.174486
1	bar	one	-0.409657	0.872421
2	foo	two	-1.278086	0.028901
3	bar	three	0.315299	-2.273053
4	foo	two	-0.147411	-0.892378
5	bar	two	0.218316	-0.693276
6	foo	one	-1.024522	-0.358686
7	foo	three	1.996648	-0.273449

		세대수	한국인남자	한국인여자	외국인남자	외국인여자
기간	자치구					
2020.1/4	중구	63045	61839	64336	4930	5364
	관악구	270760	250743	248631	8239	9049
	송파구	279301	325859	348236	3199	3589
2020.2/4	중구	63354	61697	64395	4848	5090
	관악구	273715	250829	248911	7911	8667
	송파구	280135	324317	347195	3066	3489
2020.3/4	중구	63594	61526	64274	4667	4854
	관악구	275248	250084	248490	7554	8427
	송파구	281417	323646	346685	2956	3386

```
d = {'세대수':'세대수','한국인남자':'남자',
'한국인여자':'여자','외국인남자':'남자',
'외국인여자':'여자'}
df.groupby(d, axis=1).sum()
```

	남자	세대수	여자
자치구			
중구	66769	63045	69700
관악구	258982	270760	257680
송파구	329058	279301	351825
중구	66545	63354	69485
관악구	258740	273715	257578
송파구	327383	280135	350684
중구	66193	63594	69128
관악구	257638	275248	256917
송파구	326602	281417	350071
	중구 관악구 종파구 관악구 송파구	자치구 66769 중구 66769 광막구 329058 중구 66545 광막구 258740 광파구 327383 중구 66193 광막구 257638	자치구 66769 63045 관악구 258982 270760 중규 329058 279301 중규 66545 63354 관악구 258740 273715 송파구 327383 280135

Grouping by Function

	Α	В	С	D
0	foo	one	-1.307901	1.174486
1	bar	one	-0.409657	0.872421
2	foo	two	-1.278086	0.028901
3	bar	three	0.315299	-2.273053
4	foo	two	-0.147411	-0.892378
5	bar	two	0.218316	-0.693276
6	foo	one	-1.024522	-0.358686
7	foo	three	1.996648	-0.273449

```
df.groupby(lambda x: x//2).sum()
```

```
С
                  D
0 -1.717558
           2.046907
1 -0.962787 -2.244152
2 0.070905 -1.585654
   0.972126 -0.632135
def onetwo(x):
    return 'onetwo' if x in ['one', 'two'] \
        else 'three'
df2 = df.set_index('B')
df2.groupby(onetwo).sum()
```

```
        c
        D

        onetwo
        -3.949261
        0.131468

        three
        2.311947
        -2.546502
```

Getting Results as DataFrame

- df.groupby.transform(func, ...)
 - Call the function on each group and return a DataFrame having the same indexes as the original object filled with the transformed values
 - func: Can be a string (e.g., 'mean', 'sum', etc.) for built-in aggregate functions

df['외국인평균']=df.groupby('기간')['외국인'].transform('mean')
df['외국인이많은구'] = df['외국인'] > df['외국인평균']
df

df.groupby('A').transform('s	sum')
	,

	Α	В		В
0	foo	1	0	5
1	bar	4	1	15
2	bar	3	2	15
3	bar	6	3	15
4	foo	4	4	5
5	bar	2	5	15

		세대수	한국인	외국인
기간	자치구			
2020.1/4	중구	63045	126175	10294
	관악구	270760	499374	17288
	송파구	279301	674095	6788
2020.2/4	중구	63354	126092	9938
	관악구	273715	499740	16578
	송파구	280135	671512	6555
2020.3/4	중구	63594	125800	9521
	관악구	275248	498574	15981
	송파구	281417	670331	6342

		세대수	한국인	외국인	외국인평균	외국인이많은구
기간	자치구					
2020.1/4	중구	63045	126175	10294	11456.666667	False
	관악구	270760	499374	17288	11456.666667	True
	송파구	279301	674095	6788	11456.666667	False
2020.2/4	중구	63354	126092	9938	11023.666667	False
	관악구	273715	499740	16578	11023.666667	True
	송파구	280135	671512	6555	11023.666667	False
2020.3/4	중구	63594	125800	9521	10614.666667	False
	관악구	275248	498574	15981	10614.666667	True
	송파구	281417	670331	6342	10614.666667	False

Hierarchical Indexing

Reading a Sample Dataset (I)

- seoul2020.txt:서울시 주민등록인구 (구별) 통계 (2020년 I-3분기)
 - https://data.seoul.go.kr/dataList/419/S/2/datasetView.do

기간	자치구	세대	인구	인구	인구	세대당인구	65세이상	고령자									
기간	자치구	세대	합계	합계	합계	한국인	한국인	한국인	등록외국인	등록외국인	등록외국인	세대당인구	65세이상.	고령자			
기간	자치구	세대	계	남자	여자	계	남자	여자	계	남자	여자	세대당인구	65세이상	고령자			
2020.1/	/4	합계	4,354,0	106	10,013,	781	4,874,9	95	5,138,7	86	9,733,6	55	4,742,2	17	4,991,438	280,126 132,778 147,348 2.24	1,518,239
2020.1/	/4	종로구		161,984								6,200	2.04	28,073			
2020.1/		중구		136,469								5,364	2	23,794			
2020.1/		용산구	•	246,165	•	•	•	•	•	•	9,294	7,292	2.07	39,439			
2020.1/		성동구	-	307,193	-	-	-	-	-	-	3,591	4,560	2.2	44,728			
2020.1/		광진구	-	365,990	•	•	•	•	•	•	-	8,915	2.12	48,989			
2020.1/		동대문구	-	362,793			-			-	6,306	10,331	2.09	60,367			
2020.1/		중랑구	-	400,678	-	-	-	-	•	-	2,046	3,013	2.17	66,764			
2020.1/		성북구	-	454,532	-	-	-	-	-	-	-	7,403	2.28	72,172			
2020.1/		강북구	-	316,750	-	-	-	-	-	-	1,394	2,371	2.16	61,660			
2020.1/		도봉구	-	333,495	-	-	-		-	-	895	1,362	2.39	60,023			
2020.1/		노원구	-	535,495	-	-	-	-	-	-	1,970	2,488	2.45	82,682			
2020.1/		은평구	•	482,509	•	•	•	•	•	•	1,806	2,684	2.3	82,245			
2020.1/		서대문구	-	325,875		•	-		•	-	•	8,782	2.2	53,038			
2020.1/		마포구	-	386,086		-	-	-		-	-	7,255	2.13	53,283			
2020.1/		양천구	-	460,532	-	-	-	-	-	-	1,868	2,325	2.57	62,761			
2020.1/		강서구	-	595,703	-	-	-	-	-	-	3,049	3,352	2.24	85,992			
2020.1/		구로구	-	438,308	-	-	-	-	-	-	-	-	2.29	67,432			
2020.1/		금천구	-	251,370	-	-	-	-	•	•	•	8,188	2.09	38,508			
2020.1/		영등포구	•	404,766	•	•	•	•	•	•	•	•	2.09	59,373			
2020.1/		동작구	-	407,802	•		-	-	•	-	-	7,117	2.17	63,378			
2020.1/		관악구 서초구	-	516,662			-			-	8,239	9,049	1.84	76,664			
2020.1/		시조구 강남구		434,801	-			-		-	2,090	2,143	2.48	58,332			
2020.1/		성급구 송파구	-	549,898		-	-			-	2,509	2,585	2.33	72,602			
2020.1/		공피구 강동구	-	680,883	-	-	-		-	-	3,199	3,589	2.41	89,539			
2020.1/			-	457,042	-	-	-		-	-	2,037	2,359	2.38	66,401	4 000 571	264 886 127 226 127 588 2 22	1 524 057
2020.2/		합계 조르그	4,384,0		9,985,6		4,859,5		5,126,1		9,720,8		4,732,2		4,988,571	264,806 127,226 137,580 2.22	1,534,957
2020.2/		종로구 즈그	-	160,520	-	-	-	-	-	-	-	5,680	2.02	28,203			
2020.2/ 2020.2/		중구 용산구	-	136,030		-	-				4,848	5,090	1.99	24,035			
2020.2/	4	궁연구	111,586	245,362	119,494	125,868	229,431	110,527	110,904	15,931	8,967	6,964	2.06	39,650			

Reading a Sample Dataset (2)

What's wrong?

```
import numpy as np
import pandas as pd
df = pd.read csv('seoul2020.txt', sep='\t', thousands=',')
df.head()
```

	기간	자치구	세대	인구	인구.1	인구.2	인구.3	인구.4	인구.5	인-
0	기간	자치구	세대	합계	합계	합계	한국인	한국인	한국인	등록외=
1	기간	자치구	세대	계	남자	여자	계	남자	여자	
2	2020.1/4	합계	4,354,006	10,013,781	4,874,995	5,138,786	9,733,655	4,742,217	4,991,438	280,
3	2020.1/4	종로구	74,151	161,984	78,271	83,713	151,217	73,704	77,513	10,
4	2020.1/4	중구	63,045	136,469	66,769	69,700	126,175	61,839	64,336	10,

```
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 80 entries, 0 to 79
Data columns (total 14 columns):
    Column
              Non-Null Count Dtype
    기간
                80 non-null
                               object
    자치구
                80 non-null
                               object
    세대
                               object
                80 non-null
    인구
                80 non-null
                               object
    인구.1
               80 non-null
                               object
    인구.2
               80 non-null
                               object
    인구.3
               80 non-null
                               object
    인구.4
               80 non-null
                               object
    인구.5
               80 non-null
                               object
    인구.6
               80 non-null
                               object
 10 인구.7
                80 non-null
                               object
    인구.8
                80 non-null
                               object
 12 세대당인구
                 80 non-null
                                 object
 13 65세이상고령자 80 non-null
                                  object
dtypes: object(14)
```

memory usage: 8.9+ KB

Reading a Sample Dataset (3)

Ignoring first two rows

```
df = pd.read_csv('seoul2020.txt', sep='\t', thousands=',', skiprows=2)
df.head()
```

	기간	자치구	세대	계	남자	여자	계.1	남자.1	여자.1	
0	2020.1/4	합계	4354006	10013781	4874995	5138786	9733655	4742217	4991438	28
1	2020.1/4	종로구	74151	161984	78271	83713	151217	73704	77513	1
2	2020.1/4	중구	63045	136469	66769	69700	126175	61839	64336	1
3	2020.1/4	용산구	110895	246165	119961	126204	229579	110667	118912	1
4	2020.1/4	성동구	135643	307193	149891	157302	299042	146300	152742	

<Another way of changing types>

```
df = pd.read_csv('seoul2020.txt', sep='\t')
df = df[df.자치구.isin(['관악구','송파구','중구'])]
for col in df.columns[2:]:
    if (col != '세대당인구'):
        df[col] = df[col].apply(lambda x: x.replace(',','')).astype(np.int64)
```

```
df.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 9 entries, 4 to 78
Data columns (total 14 columns):
    Column
              Non-Null Count Dtype
     기간
               9 non-null
                               object
    자치구
                9 non-null
                               object
    세대
               9 non-null
                               int64
    인구
               9 non-null
                               int64
    인구.1
               9 non-null
                               int64
    인구.2
               9 non-null
                               int64
    인구.3
               9 non-null
                               int64
    인구.4
               9 non-null
                               int64
    인구.5
               9 non-null
                               int64
    인구.6
               9 non-null
                               int64
 10 인구.7
               9 non-null
                               int64
               9 non-null
 11 인구.8
                               int64
 12 세대당인구
                 9 non-null
                                 object
 13 65세이상고령자 9 non-null
                                 int64
dtypes: int64(11), object(3)
memory usage: 1.1+ KB
```

Using Hierarchical Indexes

	총계	세대수	한국인	한국인		<u>I</u>
	수	세대	남자	여자	남자	여자
기간	자치구					
2020.1/4	중구	63045	61839	64336	4930	5364
	관악구	270760	250743	248631	8239	9049
	송파구	279301	325859	348236	3199	3589
2020.2/4	중구	63354	61697	64395	4848	5090
	관악구	273715	250829	248911	7911	8667
	송파구	280135	324317	347195	3066	3489
2020.3/4	중구	63594	61526	64274	4667	4854
	관악구	275248	250084	248490	7554	8427
	송파구	281417	323646	346685	2956	3386

Using Primary Row Index

총계 세대수 한국인 외국인 수 세대 남자 여자 남자 여자 기간 자치구 2020.2/4 61697 64395 4848 63354 5090 **관악구** 273715 250829 248911 7911 8667 송파구 280135 324317 347195 3066 3489 2020.3/4 중구 63594 61526 64274 4667 4854

관악구 275248 250084 248490 7554 8427

3386

송파구 281417 323646 346685 2956

df.loc[['2020.1/4','2020.3/4']]

	총계	세대수	한국인		외국인	<u> </u>
	수	세대	남자	여자	남자	여자
기간	자치구					
2020.1/4	중구	63045	61839	64336	4930	5364
	관악구	270760	250743	248631	8239	9049
	송파구	279301	325859	348236	3199	3589
2020.3/4	중구	63594	61526	64274	4667	4854
	관악구	275248	250084	248490	7554	8427
	송파구	281417	323646	346685	2956	3386

df['2020.2/4':'2020.3/4']

Using Secondary Row Index

df.loc[[('2020.1/4','중구'), ('2020.3/4', '관악구')]]

 df.loc[(slice(None), '중구'),:]

	총계	세대수	한국인		외국인	<u>l</u>
	수	세대	남자	여자	남자	여자
기간	자치구					
2020.1/4	중구	63045	61839	64336	4930	5364
2020.2/4	중구	63354	61697	64395	4848	5090
2020.3/4	중구	63594	61526	64274	4667	4854

Using Column Indexes

```
df.loc[(slice(None), '관악구'),
(slice(None), '여자')]
```

df['한국인']

	수	남자	여자
기간	자치구		
2020.1/4	중구	61839	64336
	관악구	250743	248631
	송파구	325859	348236
2020.2/4	중구	61697	64395
	관악구	250829	248911
	송파구	324317	347195
2020.3/4	중구	61526	64274
	관악구	250084	248490
	송파구	323646	346685

하구이

이구이

	송계	안국인	외국인
	수	여자	여자
기간	자치구		
2020.1/4	중구	64336	5364
	관악구	248631	9049
	송파구	348236	3589
2020.2/4	중구	64395	5090
	관악구	248911	8667
	송파구	347195	3489
2020.3/4	중구	64274	4854
	관악구	248490	8427
	송파구	346685	3386

Unstacking / Stacking

df2 = df['한국인'] df2 df2.unstack()

df2.unstack().stack()

		남자	여자
기간	자치구		
2020.1/4	중구	66769	69700
	관악구	258982	257680
	송파구	329058	351825
2020.2/4	중구	66545	69485
	관악구	258740	257578
	송파구	327383	350684
2020.3/4	중구	66193	69128
	관악구	257638	256917
	송파구	326602	350071

	남자			여자		
자치구	관악구	송파구	중구	관악구	송파구	중구
기간						
2020.1/4	258982	329058	66769	257680	351825	69700
2020.2/4	258740	327383	66545	257578	350684	69485
2020.3/4	257638	326602	66193	256917	350071	69128

기간 자치구 2020.1/4 관악구 258982 257680 송파구 329058 351825 중구 66769 69700 2020.2/4 관악구 258740 257578 송파구 327383 350684 중구 66545 69485 2020.3/4 관악구 257638 256917 송파구 326602 350071 중구 66193 69128			남자	여자
송파구 329058 351825 중구 66769 69700 2020.2/4 관악구 258740 257578 송파구 327383 350684 중구 66545 69485 2020.3/4 관악구 257638 256917 송파구 326602 350071	기간	자치구		
중구 66769 69700 2020.2/4 관악구 258740 257578 송파구 327383 350684 중구 66545 69485 2020.3/4 관악구 257638 256917 송파구 326602 350071	2020.1/4	관악구	258982	257680
2020.2/4관악구258740257578송파구327383350684중구66545694852020.3/4관악구257638256917송파구326602350071		송파구	329058	351825
송파구 327383 350684 중구 66545 69485 2020.3/4 관악구 257638 256917 송파구 326602 350071		중구	66769	69700
중구 66545 69485 2020.3/4 관악구 257638 256917 송파구 326602 350071	2020.2/4	관악구	258740	257578
2020.3/4관악구257638256917송파구326602350071		송파구	327383	350684
송파구 326602 350071		중구	66545	69485
0 11 32332 3333	2020.3/4	관악구	257638	256917
중구 66193 69128		송파구	326602	350071
		중구	66193	69128

Pivoting

- df.pivot (index=None, columns=None, values=None)
 - Return reshaped DataFrame organized by given index/column values
 - index: column(s) to use to make new frame's index
 - columns: column(s) to use to make new frame's columns
 - values: column(s) to use for populating new frame's values. If not specified, all remaining columns will be used and the result will have hierarchically indexed columns

	기간	자치구	세대수	한국인	외국인
2	2020.1/4	중구	63045	126175	10294
21	2020.1/4	관악구	270760	499374	17288
24	2020.1/4	송파구	279301	674095	6788
28	2020.2/4	중구	63354	126092	9938
47	2020.2/4	관악구	273715	499740	16578
50	2020.2/4	송파구	280135	671512	6555
54	2020.3/4	중구	63594	125800	9521
73	2020.3/4	관악구	275248	498574	15981
76	2020.3/4	송파구	281417	670331	6342

Pivoting Example

df.pivot('기간', '자치구', '세대수')

```
자치구 관악구 송파구 중구
기간
2020.1/4 270760 279301 63045
2020.2/4 273715 280135 63354
2020.3/4 275248 281417 63594
```

df.pivot('자치구', '기간', '세대수')

```
기간 2020.1/4 2020.2/4 2020.3/4
자치구
관악구 270760 273715 275248
송파구 279301 280135 281417
중구 63045 63354 63594
```

df.pivot('기간', '자치구', ['한국인', '외국인'])

	한국인			외국인		
자치구	관악구	송파구	중구	관악구	송파구	중구
기간						
2020.1/4	499374	674095	126175	17288	6788	10294
2020.2/4	499740	671512	126092	16578	6555	9938
2020.3/4	498574	670331	125800	15981	6342	9521

Swapping and Sorting

```
df = df.swaplevel('기간','자치구')
df
```

		세대수	한국인		외국인	
		세대	남자	여자	남자	여자
자치구	기간					
중구	2020.1/4	63045	66769	69700	4930	5364
관악구	2020.1/4	270760	258982	257680	8239	9049
송파구	2020.1/4	279301	329058	351825	3199	3589
중구	2020.2/4	63354	66545	69485	4848	5090
관악구	2020.2/4	273715	258740	257578	7911	8667
송파구	2020.2/4	280135	327383	350684	3066	3489
중구	2020.3/4	63594	66193	69128	4667	4854
관악구	2020.3/4	275248	257638	256917	7554	8427
송파구	2020.3/4	281417	326602	350071	2956	3386

df.sort_index(level=0)

		세대수	한국인		외국인	
		세대	남자	여자	남자	여자
자치구	기간					
관악구	2020.1/4	270760	258982	257680	8239	9049
	2020.2/4	273715	258740	257578	7911	8667
	2020.3/4	275248	257638	256917	7554	8427
송파구	2020.1/4	279301	329058	351825	3199	3589
	2020.2/4	280135	327383	350684	3066	3489
	2020.3/4	281417	326602	350071	2956	3386
중구	2020.1/4	63045	66769	69700	4930	5364
	2020.2/4	63354	66545	69485	4848	5090
	2020.3/4	63594	66193	69128	4667	4854

Applying Functions

df.sum(level='자치구')

df.sum(level='卆', axis=1)

수	세대수	한국인		외국인	
총계	세대	남자	여자	남자	여자
자치구					
중구	189993	199507	208313	14445	15308
관악구	819723	775360	772175	23704	26143
A -1 -			1052580	9221	10464

	수	세대수	한국인	외국인
자치구	기간			
중구	2020.1/4	63045	136469	10294
관악구	2020.1/4	270760	516662	17288
송파구	2020.1/4	279301	680883	6788
중구	2020.2/4	63354	136030	9938
관악구	2020.2/4	273715	516318	16578
송파구	2020.2/4	280135	678067	6555
중구	2020.3/4	63594	135321	9521
관악구	2020.3/4	275248	514555	15981
송파구	2020.3/4	281417	676673	6342

중구 **2020.1/4** 63045 66769 69700 4930 5364 관악구 **2020.1/4** 270760 258982 257680 8239 9049 송파구 **2020.1/4** 279301 329058 351825 3199 3589

 관악구
 2020.2/4
 273715
 258740
 257578
 7911
 8667

 송파구
 2020.2/4
 280135
 327383
 350684
 3066
 3489

 중구
 2020.3/4
 63594
 66193
 69128
 4667
 4854

 관악구
 2020.3/4
 275248
 257638
 256917
 7554
 8427

 송파구
 2020.3/4
 281417
 326602
 350071
 2956
 3386

Combining and Merging

Appending DataFrames (I)

- df.append(other, ignore_index=False, ...)
 - Append rows of other to the end of caller, returning a new object
 - left: DataFrame or Series, or list of these
 - ignore_index: If True, the resulting axis will be labeled 0, 1, ..., n-1

df1

Alice

Bob

Charlie

Emily

name country

Korea

US

UK

France

id

df2

	id	name	age
0	4	Judy	15
1	7	David	19
2	8	Bill	11

df1.append(df2)

	id	name	country	age
0	1	Alice	Korea	NaN
1	2	Bob	US	NaN
2	9	Charlie	UK	NaN
3	5	Emily	France	NaN
0	4	Judy	NaN	15.0
1	7	David	NaN	19.0
2	8	Bill	NaN	11.0

df1.append([df2, df2],
 ignore_index=True)

	id	name	country	age
0	1	Alice	Korea	NaN
1	2	Bob	US	NaN
2	9	Charlie	UK	NaN
3	5	Emily	France	NaN
4	4	Judy	NaN	15.0
5	7	David	NaN	19.0
6	8	Bill	NaN	11.0
7	4	Judy	NaN	15.0
8	7	David	NaN	19.0
9	8	Bill	NaN	11.0

Appending DataFrames (2)

Appending rows with a Python a dictionary

	id	name	country
0	1	Alice	Korea
1	2	Bob	US
2	9	Charlie	UK
3	5	Emily	France
4	8	Jack	Japan
5	6	Kate	NaN

Merging (Joining)

- pd.merge(left, right, [how], [on], [left_on], [right_on], [left_index], [right_index], ...)
 - Merge DataFrame objects with database-style join
 - left: DataFrame
 - right: Object to merge with
 - how: join type -- 'left', 'right', 'outer', or 'inner' (default: 'inner')
 - on: column to join on (label or list) -- must be found on both DataFrames
 - left_on (or right_on): column to join on in the left (or right) DataFrame
 - left_index (or right_index): if True, use the index from the left (or right) DataFrame

```
result = pd.merge(dfx, dfy, on='key')
```

	Α	В	key
0	Α0	В0	K0
1	A1	B1	K1
2	A2	B2	K2
3	АЗ	В3	K3

	С	D	key
0	C0	D0	K0
1	C1	D1	K1
2	C2	D2	K2
3	СЗ	D3	K3

	Α	В	key	С	D
0	A0	В0	K0	C0	D0
1	A1	В1	K1	C1	D1
2	A2	B2	K2	C2	D2
3	А3	ВЗ	K3	C3	D3

Columns for Merging

Merging two DataFrames by their own index

```
pd.merge(dfx, dfy,
left_index=True, right_index=True)
```



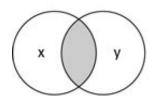
If no information is given, use overlapping column names as the keys

	Α	В	X		X	Υ	Z		Α	В	X	Υ	Z
C	A 0	В0	X0	0	X0	Y0	Z0	0	A0	В0	X0	Y0	Z0
1	A1	В1	X1	1	X1	Y1	Z1	1	A1	В1	X1	Y1	Z1
2	. A2	В2	X2	2	X2	Y2	Z2	2	A2	B2	X2	Y2	Z2
3	A3	В3	Х3	3	X3	Y3	Z3	3	А3	В3	Х3	Y3	Z3

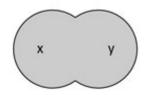
Merging (Joining) Types

- Inner join ('inner') -- default
 - Return only the rows in which the left table have matching keys in the right table
- Outer join ('outer')
 - Returns all rows from both tables, join records from the left which have matching keys in the right table.
- Left outer join ('left')
 - Return all rows from the left table, and any rows with matching keys from the right table.
- Right outer join ('right')
 - Return all rows from the right table, and any rows with matching keys from the left table.

how='inner'

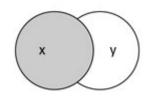


natural join how='outer'



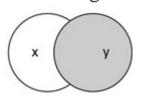
full outer join

how='left'



left outer join

how='right'



right outer join

Merging (Joining) Example

df1		id	name
	0	1	Alice
	1	2	Bob
	2	3	Charlie
	3	4	David
	4	5	Emily

df2		id	country
	0	2	Korea
	1	4	US
	2	5	UK
	3	6	Italy

		id	name	country
				,
	0	2	Bob	Korea
inner	1	4	David	US
	2	5	Emily	UK
		id	name	country
	0	1	Alice	NaN
	1	2	Bob	Korea
	2	3	Charlie	NaN
outer	3	4	David	US
	4	5	Emily	UK

6

NaN

Italy

		pd	.merg	e(df1, d
		id	name	country
	0	1	Alice	NaN
left	1	2	Bob	Korea
	2	3	Charlie	. NaN
	3	4	David	US
	4	5	Emily	UK
		id	name	country
	0	2	Bob	Korea
right	1	4	David	US
	2	5	Emily	UK
	3	6	NaN	Italy

Many-to-One Join

dfx

dfy

pd.merge(dfx, dfy)

id name
 1 Alice
 2 Bob
 3 Charlie
 4 David
 5 Emily

country Korea 0 US 1 2 US 3 UK 5 4 5 France 5 6 Italy

idnamecountry02BobKorea12BobUS24DavidUS35EmilyUK45EmilyFrance

Concatenating DataFrames (I)

- pd.concat(objs, axis=0, join='outer', keys=None, ...)
 - Append rows of other to the end of caller, returning a new object
 - objs: a sequence of DataFrame or Series
 - axis: the axis to concatenate along
 - join: how to handle indexes on other axis
 - keys: construct hierarchical index using the

keys as the outermost level

df:	1		df2	2			
	id	name	country		id	name	age
0	1	Alice	Korea	0	4	Judy	15
1	2	Bob	US	1	7	David	19
2	9	Charlie	UK	2	8	Bill	11
3	5	Emily	France				

	id	name	country	id	name	age
0	1	Alice	Korea	4.0	Judy	15.0
1	2	Bob	US	7.0	David	19.0
2	9	Charlie	UK	8.0	Bill	11.0

NaN

pd.concat([df1, df2], axis=1)

pd.concat([df1, df2])

	id	name	country	age
0	1	Alice	Korea	NaN
1	2	Bob	US	NaN
2	9	Charlie	UK	NaN
3	5	Emily	France	NaN
0	4	Judy	NaN	15.0
1	7	David	NaN	19.0
2	8	Bill	NaN	11.0

Concatenating DataFrames (2)

```
pd.concat([df1, df2], join='inner')
```

pd.concat([df1, df2],
keys=['df1','df2'])

	id	name	country	age
0	1	Alice	Korea	NaN
1	2	Bob	US	NaN
2	9	Charlie	UK	NaN
3	5	Emily	France	NaN
4	4	Judy	NaN	15.0
5	7	David	NaN	19.0
6	8	Bill	NaN	11.0

	id	name
0	1	Alice
1	2	Bob
2	9	Charlie
3	5	Emily
0	4	Judy
1	7	David
2	8	Bill

		id	name	country	age
df1	0	1	Alice	Korea	NaN
	1	2	Bob	US	NaN
	2	9	Charlie	UK	NaN
	3	5	Emily	France	NaN
df2	0	4	Judy	NaN	15.0
	1	7	David	NaN	19.0
	2	8	Bill	NaN	11.0